

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA OSIJEK
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH
TEHNOLOGIJA OSIJEK

Diplomski studij Računarstvo

Modul Umjetna inteligencija i robotika

Kolegij Strojno učenje

**KLASIFIKACIJA MEDICINSKIH SLIKA: DETEKCIJA
UPALE PLUĆA IZ RENDGENSKIH SNIMAKA**

Tehnička dokumentacija

Ivona Pranjić

Osijek, travanj, 2026.

SADRŽAJ

1.	UVOD	3
2.	EKSPLOLATIVNA ANALIZA	4
2.1.	Izvor i struktura podataka.....	4
2.2.	Eksplorativna analiza i tehničke karakteristike podataka	5
2.3.	Predobrada podataka za model.....	5
3.	OPIS KORIŠTENIH METODA I ALGORITAMA.....	8
3.1.	Arhitektura konvolucijskih neuronskih mreža (CNN).....	8
3.2.	Model građen „od nule“ (<i>baseline</i> CNN).....	8
3.3.	Prijenosno učenje i VGG16 arhitektura	10
3.4.	Grad – CAM vizualizacija.....	11
3.5.	Postavke treniranja i metrike evaluacije.....	11
4.	EVALUACIJA I REZULTATI.....	14
4.1.	Analiza procesa treniranja i validacije	14
4.2.	Evaluacija na testnom skupu podataka.....	16
4.3.	Zaključna razmatranja o performansama	17
5.	DEMONSTRACIJA RADA	19
5.1.	Izgled sučelja i tehnička implementacija	19
5.2.	Funkcioniranje Grad-CAM algoritma u aplikaciji	21
5.3.	Evaluacija finalnog rješenja i identifikacija ograničenja	22
6.	ZAKLJUČAK	24
	LITERATURA	25

1. UVOD

Detekcija upale pluća iz RTG snimaka jedan je od najčešćih dijagnostičkih izazova u današnjoj modernoj medicini. S razvojem rendgenskog snimanja te samog područja radiologije, otkrivanje bolesti dišnog sustava se uvelike olakšava i pospješuje. Posebno česta dijagnostika u području jest otkrivanje bolesti poput pneumonije, odnosno upale pluća, koja je u svojoj vrsti uzrokovana virusno ili bakterijski. [1] Pneumonija se prvenstveno otkriva preko analize rendgenske snimke prsnog koša te slušanjem pluća, krvnom slikom i sl. Ponekad u bolnicama koje su ograničene brojem dostupnih radiologa i doktora iz navedenog područja, a posebno u situacijama epidemije/pandemije kakvu smo mogli vidjeti prethodnih godina, izazov uspješne detekcije upale kod svakog pacijenta se povećava, s obzirom da je broj pacijenata nerazmjerno veći od broja dostupnih stručnjaka koji će im se posvetiti i uspješno uspostaviti dijagnozu, a samim time i liječenje. Upravo iz navedenih razloga u pripomoć dolazi automatizacija samog postupka otkrivanja pneumonije i pomoć stručnjacima u analizi snimaka pluća.[2] Motivacija za obradu teme poput klasifikacije slika pluća leži upravo u pomoći radiolozima/doktorima i brzini trijaže.

Sama pneumonija je infekcija koja uzrokuje upalu u zračnim vrećicama pluća, što se na rendgenskoj snimci vidi kao zamućenje (infiltrati). Ljudskom oku koje nije stručno u području je veoma teško detektirati svaki oblik ovakvih zamućenja, posebno na RTG snimci koja sama po sebi ima određene specifičnosti. Važno je istaknuti kako ručna interpretacija rendgenskih snimaka zahtijeva stručnost radiologa i podložna je subjektivnosti, zbog čega su računalni sustavi korisni za trijažu i potporu odlučivanju.

Ovaj rad u prvom redu pokušava riješiti problem same klasifikacije medicinskih slika, konkretno RTG snimaka pluća, analizirajući detekciju pomoću modela konvolucijske neuronske mreže izrađenog „*from scratch*“, u odnosu na detekciju pomoću prijenosnog učenja odabrane arhitekture VGG16.[3] Osim toga, implementirano je jednostavno aplikacijsko rješenje, čijim korištenjem se želi olakšati stručnjacima u donošenju odluke o mogućoj upali na snimci, što je osigurano ugrađenim prikazom gradijentne toplinske slike [4], označavajući područja koja su navela model do rezultata.

2. EKSPLOLATIVNA ANALIZA

U ovom poglavlju opisana je analiza podatkovnog skupa korištenog u svrhe ovog projekta te njegova predobrada i karakteristike.

2.1. Izvor i struktura podataka

U svrhe izrade alata za detekciju pneumonije bilo je potrebno pronaći odgovarajući skup podataka koji je u prvu ruku javno dostupan te posjeduje dovoljnu kvalitetu medicinskih snimaka kako bi uspješno trenirali i evaluirali odabrane modele. Prirodan odabir pao je na skup podataka s platforme Kaggle, pod nazivom „Chest X-Ray Images (Pneumonia)“, autora Paula Mooneya. [5]

Podatkovni skup je označen te se sastoji od dvije klase – normal i pneumonia. Osim toga, prethodno je podijeljen na tri odvojena podskupa za trening, validaciju i test. Ukupan broj slika u podatkovnom skupu je 5836, od kojih je u trening podskupu 3875 (pneumonia) i 1341 (normal), u validacijskom 16 (8 pneumonia i 8 normal) te 390 (pneumonia) i 234 (normal) unutar testnog podskupa. Slike su prikupljene od pedijatrijskih pacijenata u dobi od jedne do pet godina u medicinskom centru u Guangzhou. Sve slike su prošle proces provjere od strane dvoje stručnjaka radiologa prije nego što su označene. Također, iz originalnog skupa uklonjene su sve snimke niske kvalitete ili one koje nisu bile dijagnostički relevantne.



Slika 1 Nasumični uzorci slika zdravih pluća (Normal)



Slika 2 Nasumični uzorci slika pluća (Pneumonia)

2.2. Eksplorativna analiza i tehničke karakteristike podataka

Sve slike u skupu podataka pohranjene su u JPEG formatu. Primjetno je kako rezolucija originalnih snimaka značajno varira, što je uobičajeno kod medicinskih uređaja različitih generacija i proizvođača. Kako bi se osigurala uniformnost ulaza u konvolucijsku neuronsku mrežu, bilo je nužno izvršiti standardizaciju svih slika na fiksnu rezoluciju. [6]

Detaljnijom analizom utvrđeno je da skup podataka pati od značajnije klasne neuravnoteženosti. Od ukupno 5856 snimaka, broj slika s dijagnozom pneumonije znatno je veći od broja slika zdravih pluća. Takva pojava je sasvim logična, jer se češće na zračeće RTG snimanje šalju pacijenti kojima se preko prethodnih načina dijagnostike utvrdi povećana sumnja na upalu, dok je broj zdravih pacijenata, kojima možda upala nije na plućima znatno manji, što potvrđuje disbalans među klasama. U medicinskim istraživanjima ovo je čest izazov jer modeli prirodno teže optimizaciji prema brojnijoj klasi, što može dovesti do lažno visokog postotka metrike točnosti, dok stvarna sposobnost detekcije rjeđe klase (Normal) može biti niska. [7] Upravo zbog toga, u kasnijim fazama evaluacije modela, osim same točnosti, bit će važno analizirati metrike poput odziva i specifičnosti. [8]

2.3. Predobrada podataka za model

Kako bi se osigurala robusnost i spriječila prenaučenost (engl. *Overfitting*), nad podacima su provedeni postupci transformacije i predobrade. Sve slike su skalirane na rezoluciju od 224x224 piksela. Ova dimenzija je nužna jer odgovara standardnom ulaznom sloju odabrane VGG16 arhitekture u drugom dijelu eksperimenta. Nad slikama za treniranje primijenjene su nasumične transformacije kako bi se model naučio prepoznavati ključne značajke bez obzira na varijacije u snimanju. [6] One uključuju nasumičnu rotaciju do 10 stupnjeva koja simulira male pomake pacijenta tijekom snimanja, horizontalno zrcaljenje slike koje povećava raznolikost skupa

podataka te blage promjene u svjetlini i kontrastu koje pomažu modelu da postane otporan na različite postavke ekspozicije rendgenskih uređaja.

```
transforms.Resize((224, 224)),
transforms.RandomRotation(10),
transforms.RandomHorizontalFlip(),
transforms.ColorJitter(brightness=0.1,
contrast=0.1)
```

Programski kod 1 Transformacija podataka - isječak iz originalnog programskog koda

Osim prethodno navedenih transformacija podataka, obrađena je i njihova normalizacija. Slike su normalizirane korištenjem srednjih vrijednosti i standardne devijacije preuzete iz ImageNet skupa podataka. [9] Ovaj je postupak ključan kod prijenosnog učenja (engl. *Transfer Learning*) jer osigurava da ulazni podaci imaju istu distribuciju kao i oni na kojima je VGG16 inicijalno treniran.

```
means = [0.485, 0.456, 0.406]
stds = [0.229, 0.224, 0.225]
transforms.Normalize(means, stds)
```

Programski kod 2 Normalizacija - isječak iz programskog koda

Kako je već prethodno spomenuto, među podacima je utvrđena značajna neuravnoteženost klasa, odnosno veći broj snimaka s dijagnozom pneumonije. Iz tog razloga bilo je potrebno implementirati tehniku uzorkovanja koja će disbalans klasa smanjiti. Umjesto nasumičnog odabira slika, korišten je sampler koji svakom uzorku dodjeljuje težinu obrnuto proporcionalnu učestalosti njegove klase. Na taj način, slike iz rjeđe zastupljene klase češće se pojavljuju tijekom jedne epohe treniranja, što prisiljava model da pridaje jednaku važnost objema kategorijama i sprječava pristranost prema brojnijoj klasi. [7] Također, podaci su podijeljeni u

male serije (engl. *Batches*) veličine 16, što omogućuje stabilnije ažuriranje težina modela i učinkovitije korištenje memorije.

```
targets = np.array(train_dataset.targets)
class_sample_count = np.array([len(np.where(targets == t)[0]) for
t in np.unique(targets)])
weight = 1. / class_sample_count
samples_weight = np.array([weight[t] for t in targets])
samples_weight = torch.from_numpy(samples_weight)
sampler =
WeightedRandomSampler(samples_weight.type('torch.DoubleTensor'),
len(samples_weight))
batch_size = 16
train_loader = DataLoader(train_dataset, batch_size=batch_size,
sampler=sampler)
val_loader = DataLoader(val_dataset, batch_size=batch_size,
shuffle=False)
test_loader = DataLoader(test_dataset, batch_size=batch_size,
shuffle=False)
```

Programski kod 3 Rješavanje disbalansa klasa i definiranje DataLoader-a

3. OPIS KORIŠTENIH METODA I ALGORITAMA

Poglavlje broj 3 daje uvid u korištene metode i algoritme za konkretnu realizaciju projektnog zadatka. Stavljen je fokus na primjenu dubokog učenja, specifično konvolucijskih neuronskih mreža, koje su se pokazale kao standard u području računalnog vida i analize medicinskih slika.

3.1. Arhitektura konvolucijskih neuronskih mreža (CNN)

Konvolucijske neuronske mreže (engl. *Convolutional Neural Networks, CNN*) su vrsta neuronskih mreža koja koristi trodimenzionalne podatke za rješavanje problema kao što su klasifikacija slika ili prepoznavanje objekata. [10] One su dizajnirane da oponašaju vizualni sustav ljudi, omogućujući automatsko učenje prostornih hijerarhija značajki iz ulaznih podataka. Arhitektura se obično sastoji od ključna tri tipa slojeva:

- Konvolucijski slojevi (engl. *Convolutional Layers*): Ovo je temeljni dio mreže. Koriste se filtri (jezgre ili engl. *Kernels*) koji klize preko slike i izvode matematičku operaciju konvolucije. Na taj način mreža u početnim slojevima prepoznaje jednostavne značajke poput rubova i linija, dok u dubljim slojevima prepoznaje složenije oblike poput strukture plućnih krila ili infiltrata.
- Slojevi sažimanja (engl. *Pooling Layers*): Njihova uloga je smanjenje prostornih dimenzija mapa značajki (engl. *Downsampling*). Time se smanjuje broj parametara i računalna složenost, a mreža postaje otpornija na male pomake ili rotacije objekta na slici.
- Potpuno povezani slojevi (engl. *Fully Connected Layers*): Ovi slojevi dolaze na samom kraju mreže. Oni uzimaju apstraktne značajke prikupljene kroz prethodne slojeve i koriste ih za donošenje konačne odluke o klasifikaciji slike u jednu od kategorija.

3.2. Model građen „od nule“ (*Baseline CNN*)

Kao osnovni model za usporedbu, razvijena je jednostavnija konvolucijska neuronska mreža. Arhitektura se sastoji od tri konvolucijska bloka, gdje svaki blok sadrži konvolucijski sloj, ReLu aktivacijsku funkciju te sloj sažimanja. Na samom kraju mreže korišteni su potpuno povezani slojevi. U nastavku slijedi isječak programskog koda u kojem je definirana sama struktura ove mreže:


```

import torch.nn as nn
import torch.nn.functional as F
class PneumoniaCNN(nn.Module):
    def __init__(self):
        super(PneumoniaCNN, self).__init__()
        self.conv1 = nn.Conv2d(3, 16, 3, padding=1)
        self.conv2 = nn.Conv2d(16, 32, 3, padding=1)
        self.conv3 = nn.Conv2d(32, 64, 3, padding=1)
        self.pool = nn.MaxPool2d(2, 2)
        self.fc1 = nn.Linear(64 * 28 * 28, 512)
        self.fc2 = nn.Linear(512, 2) # 2 klase: Normal i Pneumonia
        self.dropout = nn.Dropout(0.2)
    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = self.pool(F.relu(self.conv3(x)))
        x = x.view(-1, 64 * 28 * 28) # Flattening
        x = self.dropout(x)
        x = F.relu(self.fc1(x))
        x = self.dropout(x)
        x = self.fc2(x)
        return x
model_scratch = PneumoniaCNN().to('cuda')

```

Programski kod 4 Struktura konvolucijske neuronske mreže za baseline model

Korišteno je progresivno povećanje broja filtera (16, 32, 64) kako bi mreža mogla naučiti složenije oblike u dubljim slojevima, što je posebno važno kod medicinskih problema, gdje na neki način trebamo „natjerati“ model da se fokusira na samu biologiju, a ne na okolne značajke koje se ne razlikuju kod zdravih i bolesnih pacijenata. Dimenzija 64*28*28 proizlazi iz ulazne slike 224x224, koja je tri puta prošla kroz slojeve maksimalnog sažimanja (engl. *MaxPooling*). Također, korištena je tehnika regularizacije - postavljen je blagi *dropout* od 20% kako bi se smanjila ovisnost o pojedinačnim neuronima i potaknula bolja generalizacija.

3.3. Prijenosno učenje i VGG16 arhitektura

U drugom dijelu istraživanja primijenjen je pristup prijenosnog učenja (engl. *Transfer Learning*) korištenjem arhitekture VGG16. Glavna ideja ovog pristupa je iskorištavanje znanja koje je model stekao treniranjem na ogromnom skupu podataka te njegova primjena na specifičnu domenu medicinske dijagnostike.

```
from torchvision import models

model_vgg = models.vgg16(pretrained=True)
for param in model_vgg.features.parameters():
    param.requires_grad = False
n_inputs = model_vgg.classifier[6].in_features
model_vgg.classifier[6] = nn.Sequential(
    nn.Linear(n_inputs, 256),
    nn.ReLU(),
    nn.Dropout(0.4),
    nn.Linear(256, 2)
)
model_vgg = model_vgg.to('cuda')
```

Programski kod 5 Implementacija modela s predtreniranim težinama

Kako bi se zadržala sposobnost modela da prepozna osnovne značajke (rubove, sjene, teksture), parametri konvolucijskih slojeva su zamrznuti (`requires_grad = False`). Time se sprječava njihovo mijenjanje tijekom treniranja, što drastično ubrzava proces i sprječava gubitak već naučenih informacija. Budući da je originalni VGG16 dizajniran za klasifikaciju 1000 različitih objekata, zadnji sloj je zamijenjen novim `nn.Sequential` blokom. On smanjuje dimenzionalnost na 256 neurona, a zatim na dva konačna izlaza, koji odgovaraju binarnim klasama ovog istraživanja. U ovoj dubljij arhitekturi korišten je nešto agresivniji *dropout* od 40%. S obzirom na to da VGG16 ima ogroman broj parametara, veći *dropout* je nužan kako bi se osiguralo da se model ne „sjeća“ slika iz trening skupa, već da uči generalna pravila detekcije upale.

3.4. Grad – CAM vizualizacija

Kako bi se omogućila transparentnost odluka modela, implementirana je metoda Grad – CAM (engl. *Gradient – weighted Class Activation Mapping*). Ova metoda vizualizira područja slike na koja se VGG16 model najviše fokusirao prilikom donošenja klasifikacijske odluke. U okviru ovog rada, Grad-CAM je implementiran izravno kroz PyTorch mehanizme, prateći sljedeće korake vidljive u izvornom programskom kodu:

1. Korištenje „hook“ funkcija: Budući da standardni prolaz kroz mrežu (engl. *Forward Pass*) ne zadržava gradijente srednjih slojeva, korištene su funkcije `register_forward_hook` i `register_full_backward_hook`. [11] One omogućuju „hvatanje“ aktivacija i gradijenata iz ciljanog sloja u trenutku izračuna.
2. Ciljani sloj (engl. *Target Layer*): Za vizualizaciju je odabran posljednji konvolucijski sloj VGG16 arhitekture, koji sadrži najbogatije prostorne informacije i visoku razinu apstrakcije značajki. [12]
3. Na temelju gradijenata izračunatih povratnim širenjem pogreške (engl. *Backpropagation*) za pobjedničku klasu, određuju se težine za svaku mapu značajki. Težine se dobivaju usrednavanjem gradijenata po prostornim dimenzijama (`np.mean(grads, axis=(2,3))`)
4. Generiranje toplinske karte dobiva se linearnom kombinacijom mapa značajki i njihovih težina, nakon čega se primjenjuje ReLU aktivacija kako bi se zadržali samo pozitivni utjecaji na odluku.
5. Obrada i prikaz: Mapa se skalira na dimenzije ulazne slike (224x224) te se prikazuje pomoću *jet* palete boja uz prozirnost 0.5. Time se dobiva vizualni efekt gdje toplije boje (crvena) označavaju regije koje su „uvjerile“ model da se na snimci nalazi upala.

Implementirana funkcija `show_random_gradcam` omogućuje nasumičnu provjeru modela na testnom skupu. U medicinskom kontekstu, ovo je od presudne važnosti jer omogućuje radiologu da provjeri preklapaju li se žarišta koja je označio model s kliničkim infiltratima vidljivim na RTG snimci. Time se na određeni način AI sustav transformira iz „crne kutije“ u alat koristan za potporu pri trijaži pacijenata.

3.5. Postavke treniranja i metrike evaluacije

Kako bi se osigurala objektivna usporedba između modela građenog od nule i modela temeljenog na prijenosnom učenju, oba su sustava evaluirana korištenjem identičnog skupa klasifikacijskih metrika.

Treniranje je provedeno u razvojnom okruženju Google Colab uz korištenje GPU ubrzanja. Za oba modela korištena je *CrossEntropyLoss* kao funkcija gubitka, koja je standard za probleme klasifikacije jer kažnjava odstupanja predviđenih vjerojatnosti od stvarnih oznaka klasa. Kao optimizator odabran je Adam (engl. *Adaptive Moment Estimation*). Njegova glavna prednost je što prilagođava stopu učenja za svaki parametar zasebno, što se pokazalo izrazito učinkovitim u dubokom učenju.

Važno je napomenuti da za razliku od *baseline* modela gdje je stopa učenja 0.001, kod modela za prijenosno učenje ona je smanjena deset puta (0.0001). Razlog tome je što je model već predtreniran, pa su potrebne minimalne korekcije težina kako bi se očuvalo već postojeće znanje o vizualnim značajkama.

Osim toga, implementiran je i *StepLR scheduler*, koji svakih 7 epoha smanjuje stopu učenja za faktor 10. Na početku treninga veća stopa učenja omogućuje modelu da brzo uči opće značajke. Kako trening napreduje i gubitak se smanjuje, *scheduler* reducira stopu učenja kako bi model mogao pažljivije pretraživati prostor parametara i izbjeći preskakanje globalnog minimuma funkcije gubitka. Sam trening proveden je kroz 10 epoha, što predstavlja dovoljan broj prolazaka kroz cijeli skup podataka da bi se uočili trendovi učenja bez prevelikog rizika od *overfittinga*.

Za medicinsku dijagnostiku, puka točnost (engl. *Accuracy*) često nije dovoljan pokazatelj kvalitete modela. Stoga je implementirana funkcija `calculate_metrics` koja izračunava sljedeće ključne metrike:

- Točnost: Ukupan postotak točno klasificiranih uzoraka.
- Preciznost (engl. *Precision*): Udio stvarno oboljelih među svim pacijentima koje je model klasificirao kao bolesne. Visoka preciznost smanjuje broj lažno pozitivnih nalaza.
- Odziv (engl. *Recall*): Sposobnost modela da identificira sve pacijente koji doista imaju pneumoniju. U medicini je ovo ključna metrika, jer propuštanje bolesnog pacijenta (lažno negativan nalaz) može imati ozbiljne posljedice.
- Specifičnost (engl. *Specificity*): Sposobnost modela da ispravno prepozna zdrave pacijente. Izračunava se iz matrice zabune (engl. *Confusion Matrix*) pomoću formule:

$$\text{Specifičnost} = \frac{TN}{TN + FP}$$

Jednadžba 1 Specifičnost


- F1 mjera: Harmonijska sredina preciznosti i odziva, koja daje uravnoteženu ocjenu kvalitete modela, posebno korisnu kod disbalansa klasa.
- Sve metrike izvedene su iz matrice zabune, koja prati četiri osnovna ishoda:
 1. Stvarno pozitivan (engl. *True Positive*) (TP): Pacijent ima upalu i model je to točno prepoznao.
 2. Stvarno negativan (engl. *True Negative*) (TN): Pacijent je zdrav i model je to točno prepoznao.
 3. Lažno pozitivan (engl. *False Positive*) (FP): Pacijent je zdrav, ali model pogrešno tvrdi da ima upalu.
 4. Lažno negativan (engl. *False Negative*) (FN): Pacijent ima upalu, ali model pogrešno tvrdi da je zdrav.

4. EVALUACIJA I REZULTATI

U ovom poglavlju fokus je na to kako su modeli radili na treningu i validaciji te na testnom skupu podataka.

4.1. Analiza procesa treniranja i validacije


Prvi korak evaluacije je analiza ponašanja modela rijekom 10 epoha treniranja. Na slici 3 su prikazani grafovi kretanja gubitka i ključnih metrika za *baseline* model:



Slika 3 Krivulje učenja i metrike performansi za *baseline* model

Primjetne su značajne oscilacije u validacijskom gubitku i točnosti. Dok trening metrike (plava krivulja) glatko napreduju, validacijske metrike (crvena krivulja) pokazuju cikličke skokove i padove. To ukazuje na to da se jednostavnija arhitektura teže generalizira na validacijskom skupu. Zanimljivo je primijetiti da u trenucima kada odziv raste na 1.0 (savršen odziv), specifičnost drastično pada. To sugerira da model u tim trenucima postaje „preoprezan“ i klasificira gotovo sve slike kao upalu kako ne bi pogriješio, što rezultira velikim brojem lažno pozitivnih rezultata.

VGG16 model pokazuje značajno stabilnije performanse, što je sasvim u skladu s očekivanim (Slika 4):



Slika 4 Krivulje učenja i metrike performansi za VGG16 model

Za razliku od *baseline* modela, odziv na validacijskom skupu kod VGG16 ostaje konstantno na maksimalnoj vrijednosti kroz svih 10 epoha. Ovo je najvažniji rezultat za sustav rane detekcije pneumonije, iako je vrlo važno napomenuti kako validacijski skup sadrži iznimno malo slika, tako da ove rezultate treba uzeti sa određenom zadržkom.


Zanimljivo je uočiti nagli pad validacijske točnosti i specifičnosti nakon 6. epohe. Ovo se poklapa s trenutkom kada je aktiviran prethodno spomenuti *StepLR scheduler*. Iako je stopa učenja smanjena, model je na malom validacijskom skupu počeo pokazivati znakove zasićenja ili laganog *overfittinga* na trening podatke, što je rezultiralo s nekoliko lažno pozitivnih klasifikacija.

U prvih 6 epoha, VGG16 je postizao savršene rezultate na validacijskom skupu, što potvrđuje da su predtrenirane značajke iz ImageNet baze prilično kompatibilne s teksturama RTG snimaka pluća.


Dok je *baseline* model uspio postići visoke rezultate samo u izoliranim epohama, VGG16 je pokazao robusnost. Vrijeme treniranja od 27 minuta za VGG16 opravdano je značajno nižim i stabilnijim gubitkom te konstantno visokim odzivom.

4.2. Evaluacija na testnom skupu podataka

Nakon završenog procesa treniranja, oba su modela testirana na nezavisnom testnom skupu kako bi se utvrdila njihova stvarna moć generalizacije. Rezultati su prikazani usporednim stupčastim grafom (Slika 5) te matricama zabune (Slika 6):



Slika 5 Konačna usporedba modela na testnom skupu




Slika 6 Matrice zabune oba modela

Analizom metrika i histograma, možemo prvo primijetiti kako VGG16 model ostvaruje značajno višu ukupnu točnost u odnosu na *baseline* model. Također, oba modela pokazuju iznimno visoke vrijednosti odziva. U medicinskom kontekstu, ovo znači da su oba modela uspjela detektirati gotovo sve pacijente s upalom pluća, što je primarni cilj sustava. Što se tiče specifičnosti, ovdje se upravo vidi najveća razlika. *Baseline* model ima vrlo nisku specifičnost, što znači da većinu zdravih pacijenata pogrešno klasificira kao bolesne. VGG16 značajno popravljja ovaj rezultat, iako i dalje ostavlja prostora za poboljšanje u eliminaciji lažno pozitivnih nalaza.

Uvidom u matrice zabune pruža se nešto dublji uvid u vrstu pogrešaka koje modeli rade. Kod *baseline* modela, propušten je samo jedan pacijent s upalom pluća, ali je čak 157 zdravih pacijenata proglasio bolesnima. Ovakav model bi u kliničkoj praksi izazvao preopterećenje sustava zbog prevelikog broja lažnih uzbuna. Kod VGG16, model je propustio 7 bolesnih pacijenata, ali je drastično smanjio broj lažno pozitivnih na 76. Vidljivo je da ovakav model puno bolje razlikuje zdrave nalaze, što potvrđuje 158 točno klasificiranih pacijenata u usporedbi sa samo 77 kod *baseline* modela.

4.3. Zaključna razmatranja o performansama

Iako *baseline* model ima minimalan broj lažno negativnih rezultata, on to postiže na račun izrazito niske specifičnosti. VGG16 model se nameće kao optimalno rješenje jer postiže bolju ravnotežu (F1 mjera: 0.90) i znatno je pouzdaniji u prepoznavanju zdravih pacijenata.



Slika 7 Grad-CAM vizualizacija nasumične slike iz testnog skupa


Preliminarni uvid u Grad-CAM vizualizaciju ukazuje na to da model često fokusira pažnju na anatomske strukture izvan plućnog parenhima, poput koštanih struktura ramenog pojasa. S obzirom na to da je ovo ključno za pouzdanost sustava u kliničkom okruženju, detaljna analiza vizualizacija, utjecaj koštanih sjena i problem interpretabilnosti modela bit će zasebno obrađeni u idućem poglavlju.

5. DEMONSTRACIJA RADA

U ovom poglavlju detaljno je prikazana implementacija korisničkog sučelja te način na koji krajnji korisnik (npr. radiolog ili medicinsko osoblje) koristi razvijeni sustav.


5.1. Izgled sučelja i tehnička implementacija

Aplikacija je izgrađena pomoću biblioteke Streamlit [13], koja omogućuje brz i jednostavan prikaz primjene modela dubokog učenja u obliku web stranice.



Slika 8 Početno korisničko sučelje pri pokretanju aplikacije

Kako se može vidjeti na slici 8, pri samom pokretanju aplikacije na ekranu se nalazi jednostavno korisničko sučelje. Sastoji se od naslova aplikacije ispod kojeg stoji kratak opis, koji ukazuje na to da je aplikacija samo pomoć pri dijagnozi koju konačno uspostavlja medicinsko osoblje. Nakon naslova i opisa, implementirana je funkcionalnost za učitavanje datoteka (snimke pluća) u standardnom JPG ili PNG formatu.



Slika 9 Prikaz sučelja nakon učitavanja datoteke sa bočnim prozorom

Nakon učitavanja odabrane datoteke u aplikaciju, automatski se otvara dodatna funkcionalnost - bočni prozor za izrezivanje fokusirane regije. Ova opcija je dodana u aplikaciju s ciljem da se reducira pažnja modela na koštane regije, koje su lažno ukazivale na bolesne pacijente. Korisnik sam jednostavno može fokusirati na određenu zonu sa snimke, iako se ne preporuča preveliko rezanje snimke, jer time nije vidljiva šira slika kako bi se konačno dobila dijagnoza od strane modela.

U finalnoj verziji aplikacije, koristi se model temeljen na arhitekturi VGG16, koji je odabran zbog svoje stabilnosti i dokazano boljih performansi na testnom skupu u odnosu na baseline model. Iako je model treniran na GPU, u aplikaciji se izvodi na procesoru (CPU), što osigurava pristupačnost i brzinu izvođenja na standardnim računalima.

Nakon što korisnik učitava snimku i po potrebi je izreže, sustav provodi ključni niz transformacija prije same klasifikacije:


- CLAHE (engl. *Contrast Limited Adaptive Histogram Equalization*): Ovo je prva i najvažnija faza digitalne obrade slike u aplikaciji. Za razliku od standardnog izjednačavanja histograma, CLAHE obrađuje sliku u manjim blokovima, čime se sprječava pretjerano pojačavanje šuma i postiže bolji kontrast između mekih tkiva i upalnih procesa u plućima. [14]

- Slika se skalira na dimenzije 224x224 piksela kako bi odgovarala ulaznom sloju VGG16 mreže. Zatim se pretvara u tenzor i normalizira.
- Model učitava predtrenirane težine pohranjene na Hugging Face repozitoriju. Klasifikator modela prilagođen je binarnom problemu s Dropout slojem od 40% kako bi se osigurala robusnost predikcije u realnom vremenu.

5.2. Funkcioniranje Grad-CAM algoritma u aplikaciji

Srž „objašnjivosti“ (engl. *Explainability*) aplikacije leži u funkciji `generate_gradcam`. Algoritam radi na sljedeći način:

1. Ekstrakcija značajki: Sustav se fokusira na zadnji konvolucijski sloj VGG16 arhitekture, jer sadrži najkompleksnije prostorne informacije o slici.
2. Povratno širenje gradijenta: Tijekom analize, izračunavaju se gradijenti predviđene klase u odnosu na mapu značajki tog sloja. Ovi gradijenti govore modelu koji su dijelovi slike najviše doprinijeli konačnoj odluci.
3. Generiranje toplinske karte: Težine dobivene iz gradijenata primjenjuju se na mape značajki, a rezultat prolazi kroz ReLU funkciju kako bi se zadržali samo pozitivni utjecaji. Konačna mapa se skalira na originalnu veličinu slike i prikazuje korisniku.



Slika 10 Prikaz rezultata predikcije modela


5.3. Evaluacija finalnog rješenja i identifikacija ograničenja

Razvijena aplikacija predstavlja funkcionalan prototip sustava za potporu medicinskom odlučivanju, no njezina primjena u stvarnom kliničkom okruženju zahtijeva dublje razumijevanje uočenih ograničenja.

Zahvaljujući integraciji s Hugging Face platformom, aplikacija je lako prenosiva i ne zahtijeva lokalno pohranjivanje velikih modela težina, što je demonstrirano uspješnim učitavanjem modela putem HTTP protokola.


Implementacija CLAHE metode značajno je doprinijela čitljivosti RTG snimaka, omogućujući modelu (i liječniku) jasniji uvid u teksture plućnog tkiva koje bi inače bile potisnute niskim kontrastom.

Uvođenje opcije ručnog izrezivanja (engl. *Crop*) u bočnoj traci, pokazalo se kao nužan korak za smanjivanje problema fokusa modela, dajući korisniku moć da usmjeri pažnju algoritma na medicinski relevantne zone.



Slika 11 Točno detektirana zdrava pluća

Na slici 11 možemo vidjeti kako aplikacija s lijepo fokusiranom zonom točno klasificira zdrava pluća. Također, regije koje su označene na toplinskoj karti zaista prikazuju realna područja koja bi stručnjak iz područja pregledao, što ukazuje da u ovom primjeru model fokus usmjerava tamo gdje je i predviđeno.



Slika 12 Točno detektirana pneumonija s loše označenim područjima "upale"

Iz primjera slike 12, možemo vidjeti klasičan slučaj gdje model griješi. Iako je točno detektirao da se radi o slici pluća s pneumonijom, pogrešno je fokusirao svoju predikciju na oštre rubove vidljivih koštanih struktura na snimci. Svakako, dobra je stvar što u donjem dijelu snimke prepoznaje zamućenja koja je ipak u nekom omjeru uzeo kao relevantan pokazatelj prisutne pneumonije.

6. ZAKLJUČAK

Cilj ovog projekta bio je razvoj i evaluacija sustava temeljenog na dubokom učenju za detekciju pneumonije iz RTG snimaka prsnog koša, s posebnim naglaskom na interpretabilnost modela. Kroz usporedbu modela građenog od nule i predtrenirane VGG16 arhitekture, potvrđena je superiornost prijenosnog učenja u uvjetima ograničenog skupa podataka.

Glavni izazov razvijenog rješenja ostaje problem pouzdanosti i vizualnih prečaca. Iako VGG16 model na testnom skupu pokazuje izniman odziv, Grad-CAM vizualizacija unutar same aplikacije razotkriva da model često donosi odluke na temelju sekundarnih značajki, poput rubova rebara ili ključnih kosti, umjesto na temelju stvarne prisutne patologije. Ova spoznaja naglašava opasnost od tzv. „crne kutije“ u medicinskom dubokom učenju, gdje visoke statističke metrike mogu sakriti pogrešne uzročno-posljedične veze.

Zbog zabilježene specifičnosti od 67.5% za VGG16 model i njegove tendencije da reagira na koštane strukture, aplikacija se u trenutnom stanju ne može smatrati neovisnim dijagnostičkim alatom. Međutim, njezina prava vrijednost leži u transparentnosti. Implementacijom Grad-CAM mape, aplikacija ne skriva svoje pogreške, već educira korisnika o tome kada predikciji treba vjerovati. Time sustav prestaje biti pasivni generator rezultata i postaje interaktivni alat koji potiče kritičko razmišljanje i ljudski nadzor.

Kao logičan nastavak istraživanja nameće se uvođenje modela za automatsku segmentaciju pluća, čime bi se eliminirao utjecaj okolnih tkiva i kostiju, te treniranje na značajno većim i kvalitetnijim bazama podataka. Ovakav pristup, u kombinaciji s daljnjim razvojem tehnika objašnjivosti (XAI, engl. *Explainable AI*), predstavlja temelj za modernu, sigurnu i etičnu primjenu umjetne inteligencije u zdravstvu.

LITERATURA

- [1] Pneumonia, World Health Organization. https://www.who.int/health-topics/pneumonia#tab=tab_1 zadnji pristup: 28.4.2026.
- [2] Kermany DS, Goldbaum M, Cai W, Valentim CCS, Liang H, Baxter SL, McKeown A, Yang G, Wu X, Yan F, Dong J, Prasadha MK, Pei J, Ting MYL, Zhu J, Li C, Hewett S, Dong J, Ziyar I, Shi A, Zhang R, Zheng L, Hou R, Shi W, Fu X, Duan Y, Huu VAN, Wen C, Zhang ED, Zhang CL, Li O, Wang X, Singer MA, Sun X, Xu J, Tafreshi A, Lewis MA, Xia H, Zhang K. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*. 2018 Feb 22;172(5):1122-1131.e9. doi: 10.1016/j.cell.2018.02.010. PMID: 29474911. <https://pubmed.ncbi.nlm.nih.gov/29474911/> zadnji pristup: 28.4.2026.
- [3] Simonyan, K., & Zisserman, A. (2014). "Very Deep Convolutional Networks for Large-Scale Image Recognition". <https://arxiv.org/abs/1409.1556> zadnji pristup: 28.4.2026.
- [4] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization". *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618-626. <https://ieeexplore.ieee.org/document/8237336> zadnji pristup: 28.4.2026.
- [5] Chest X-Ray Images (Pneumonia), Mooney, P. <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia> zadnji pristup: 28.4.2026.
- [6] Yadav, S. S., & Jadhav, S. M. (2019). "Deep convolutional neural network based medical image classification for disease diagnosis". *Journal of Big Data*, 6(1). <https://link.springer.com/article/10.1186/s40537-019-0276-2> zadnji pristup: 28.4.2026.
- [7] Buda, M., Maki, A., & Mazurowski, M. A. (2018). "A systematic study of the class imbalance problem in convolutional neural networks". *Neural Networks*, 106, 249-259. <https://arxiv.org/abs/1710.05381> zadnji pristup: 28.4.2026.
- [8] Hicks, S. A., et al. (2022). "On Evaluation Metrics for Medical Applications of Artificial Intelligence". *Scientific Reports*. <https://www.nature.com/articles/s41598-022-09954-8> zadnji pristup: 28.4.2026.
- [9] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei, "ImageNet: A large-scale hierarchical image database," 2009 IEEE Conference on Computer Vision and Pattern

Recognition, Miami, FL, USA, 2009, pp. 248-255, doi: 10.1109/CVPR.2009.5206848.
<https://ieeexplore.ieee.org/document/5206848> zadnji pristup: 28.4.2026.

[10] IBM, „What are convolutional neural networks?“, <https://www.ibm.com/think/topics/convolutional-neural-networks> zadnji pristup: 29.4.2026.

[11] PyTorch Documentation, „Autograd mechanics“, <https://docs.pytorch.org/docs/stable/notes/autograd.html#backward-hooks-execution> zadnji pristup: 29.4.2026.

[12] Gildenblat, J., „PyTorch library for CAM methods“, GitHub, 2021.
<https://github.com/jacobgil/pytorch-grad-cam> zadnji pristup: 29.4.2026.

[13] Streamlit documentation, <https://docs.streamlit.io/> zadnji pristup: 30.4.2026.

[14] Enhance Local Contrast (CLAHE), <https://imagej.net/plugins/clahe> zadnji pristup: 30.4.2026.